



SECURITY

Anthropic.

AI Agents-ის უსაფრთხოების გზამკვლევი.

წყარო:

Anthropic Security Guide, June 2026

რა მოხდა?

Anthropic-მა გამოაქვეყნა 36-გვერდიანი გზამკვლევი.

თემა: AI agents-ის უსაფრთხოება.

გზამკვლევაში ჩამოთვლილია 10 ძირითადი საფრთხე.

თითო საფრთხეს თან ახლავს გადაჭრის გზა.

ფაქტები

36 გვერდი · 10 საფრთხე · უფასოდ ხელმისაწვდომი.

SOURCE

Anthropic Official, June 2026

02

CORE MESSAGE

მთავარი გზავნილი.

ბრმად ნდობა — საფრთხეა.

AI agent-ი ბოროტი არ არის.

თუმცა, მისი მოტყუება შესაძლებელია.

მაგალითად: ვებგვერდზე დამალული ბრძანება.

agent-ი ვერ ხედავს მას, მაგრამ შეასრულებს.

SOURCE

Anthropic Security Guide, page 4

TAMARKHATIASHVILI

-> SWIPE

03

THREATS

5 ძირითადი საფრთხე.

01 Prompt Injection

დამალული ბრძანებები ტექსტში.

02 Data Leakage

კონფიდენციალური მონაცემების გაჟონვა.

03 Tool Misuse

ხელსაწყოს არასწორი გამოყენება.

04 Excessive Permissions

ზედმეტი წვდომები agent-ისთვის.

05 Weak Monitoring

სუსტი მონიტორინგი და ლოგინგი.

SOURCE

Anthropic Security Guide, pages 8-22

04

PRACTICAL RULES

4 პრაქტიკული წესი.

01 მინიმალური წვდომები

agent-ს მიეცი მხოლოდ ის, რაც აუცილებლად სჭირდება.

02 Sandbox + დადასტურება

მნიშვნელოვან მოქმედებას agent ადამიანის ნებართვით ასრულებს.

03 Input/Output ვალიდაცია

ყველაფერი, რასაც agent კითხულობს ან წერს, უნდა შემოწმდეს.

04 მონიტორინგი და ლოგინგი

ყველა ნაბიჯი უნდა ჩაინეროს.

SOURCE

Anthropic Security Guide, pages 24-32

რას ნიშნავს ჩვენთვის?

ჩემი 3 დაკვირვება:

- 01** AI agent-ი ხელსაწყოა — თვითონ უსაფრთხო არ არის.
- 02** პასუხისმგებლობა ჩვენზე გადადის — შემქმნელებზე და მომხმარებლებზე.
- 03** წესების დაცვა აუცილებელია — განსაკუთრებით კლიენტებთან მუშაობისას.

ცადეთ თვითონ.

ვერიფიცირებული წყაროები:

01 Anthropic Official

anthropic.com/news

02 X Post (Cyril)

x.com/cyrilXBT/status/2063886252706041974

03 Anthropic Research

anthropic.com/research

ეს ფაქტებია — არა ჩემი მოსაზრება.

გადადით ლინკებზე და დარწმუნდით თვითონ.